

LAPORAN PROYEK TEKNOLOGI CERDAS

Prediksi Customer Churn: Business Intelligence, Machine Learning, dan LLM Analyst

Komponen	Keterangan
Status	Proyek referensi / track reproduce
Ruang lingkup	Dataset e-commerce yang dibundel di repository; dashboard Streamlit; Random Forest; Ollama LLM
Unit prediksi	Satu pelanggan dengan label churned (0/1)
Snapshot data	2026-04-01
Penyusun	Belum diisi - lengkapi identitas mahasiswa sebelum penyerahan

Ringkasan eksekutif

Proyek ini membangun alur data-ke-keputusan untuk membantu manajer retensi mengidentifikasi pelanggan yang berisiko churn. Data pelanggan dan transaksi divalidasi, diringkas sebagai business intelligence, lalu dipakai oleh model klasifikasi. Skor model dan bukti transaksi diteruskan ke LLM lokal hanya untuk menyusun rekomendasi berbasis evidence. Pada test set 1.600 pelanggan, Random Forest mencapai ROC-AUC 0,733 dan F1 churn 0,387 pada threshold 0,50. Hasil ini berguna sebagai demonstrasi pembelajaran, tetapi belum cukup untuk keputusan otomatis atau klaim kausal.

Kata kunci: customer churn; business intelligence; Random Forest; Streamlit; Ollama; grounded LLM.

1. Masalah, tujuan, dan kontribusi

Churn pelanggan dapat mengurangi pendapatan berulang, sementara tim retensi perlu memprioritaskan pelanggan dengan sumber daya terbatas. Dashboard deskriptif saja tidak memberi urutan risiko individual; sebaliknya skor model tanpa konteks sulit ditindaklanjuti. Sistem ini menggabungkan keduanya: BI menjelaskan kondisi agregat, ML mengestimasi probabilitas churn, dan LLM mengubah evidence yang diberikan menjadi saran singkat untuk manajer.

Pertanyaan	Jawaban/evidence dalam proyek
RQ1 - Seberapa baik prediksi churn?	Dievaluasi pada hold-out test set dengan precision, recall, F1, ROC-AUC, dan confusion matrix.
RQ2 - Apa dampak threshold?	Dibandingkan pada 0,30; 0,50; dan 0,70 untuk memperlihatkan trade-off false positive dan false negative.
RQ3 - Apa peran LLM?	Mengkomunikasikan profil, pesanan terakhir, probabilitas ML, dan faktor global; prompt melarang faktor internal.
Kontribusi	Implementasi referensi end-to-end yang dapat direproduksi, bukan proyek adaptasi/orisinal.

2. Data dan kualitas

Repository tidak mendokumentasikan URL, lisensi, atau pemilik asli dataset. Karena itu laporan ini menyebutnya sebagai data e-commerce pembelajaran yang dibundel, bukan mengklaim provenance Kaggle tertentu. Sebelum penggunaan di luar kelas, provenance, izin, periode pengumpulan, dan kebijakan privasi wajib diverifikasi.

Tabel	Unit	Jumlah	Peran
customers.csv	pelanggan	8,000	target churn dan fitur pelanggan
orders.csv	pesanan	25,000	evidence transaksi dan return
product_summary.csv	produk	140	ringkasan BI produk
monthly_revenue.csv	bulan	75	tren revenue delivered

Pemeriksaan	Hasil	Implikasi
Prevalensi churn	8.94%	Kelas minoritas; accuracy bukan metrik tunggal.
Rating pesanan missing	63.0%	Rating perlu diperlakukan hati-hati pada analisis transaksi.
Return rate pesanan	8.08%	Gunakan orders.csv untuk analisis return.
return_rate bulanan	0 untuk semua bulan	Agregat bulanan hanya merepresentasikan order Delivered; tidak valid untuk menyimpan data yang hilang.
Konsistensi agregat	Lolos	Revenue produk cocok dengan non-cancelled; revenue bulanan cocok dengan delivered.

3. Metode dan arsitektur

Alur sistem: CSV sumber -> validasi dan cleaning -> feature engineering -> BI dashboard + pipeline ML -> probabilitas churn -> evidence pelanggan/pesanan + faktor model -> Ollama LLM -> rekomendasi untuk pengguna. LLM tidak mengubah skor model dan tidak diberi akses ke data di luar evidence yang dirangkai aplikasi.

Tahap	Implementasi
Validasi	Memeriksa kolom wajib pada empat CSV serta semantik agregasi.
Feature engineering	Tenure pelanggan, orders per year, reviews per order, dan returns per order; total 21 fitur sebelum one-hot encoding.
Split	Stratified hold-out 80:20, random_state=42; train 6.400 dan test 1.600 pelanggan.
Preprocessing	Median imputation numerik; most-frequent imputation kategorikal; OneHotEncoder(handle_unknown=ignore).
Model	RandomForestClassifier: 350 trees, min_samples_leaf=3, class_weight=balanced, random_state=42.
LLM	Ollama model default llama3.2, temperature 0,2; prompt menyatakan skor bukan kausalitas dan melarang prompt yang mengarah ke tindakan.
Aplikasi	Streamlit: data, BI, prediksi dengan threshold interaktif, dan analyst LLM.

4. Desain evaluasi

Model dievaluasi pada test set yang tidak digunakan untuk fitting. Karena churn hanya sekitar 9%, F1, precision, recall, dan ROC-AUC dilaporkan bersama accuracy. Baseline naif yang selalu memprediksi tidak churn akan memperoleh accuracy kira-kira 91,1% pada distribusi test, tetapi recall dan F1 churn 0; ini menunjukkan mengapa accuracy tinggi tidak cukup untuk tujuan retensi.

Evaluasi LLM pada repository ini masih bersifat pemeriksaan prompt dan demo runtime, bukan studi pengguna terstruktur. Oleh sebab itu, laporan tidak mengklaim tingkat konsistensi LLM secara kuantitatif.

5. Hasil

Metrik test set	Nilai
Accuracy	0.863
Precision churn	0.322
Recall churn	0.483
F1 churn	0.387
ROC-AUC	0.733
Churn rate test	0.089

Pada threshold 0,50, confusion matrix adalah TN=1.312, FP=145, FN=74, TP=69. Dengan demikian, model menangkap 69 dari 143 pelanggan churn pada test set, tetapi juga menandai 145 pelanggan non-churn. Threshold harus dipilih berdasarkan biaya intervensi dan biaya kehilangan pelanggan, bukan hanya satu skor agregat.

Threshold	Precision	Recall	F1	FP	FN
0,30	0,270	0,601	0,372	233	57
0,50	0,322	0,483	0,387	145	74
0,70	0,414	0,084	0,140	17	131

Threshold 0,30 menangkap lebih banyak churn namun memperbesar daftar kontak; threshold 0,70 menghasilkan presisi lebih tinggi tetapi melewatkan hampir semua churn. Pada metrik F1, 0,50 adalah yang terbaik dari tiga threshold yang diperiksa.

6. Interpretasi model

Feature importance Random Forest adalah kontribusi prediktif global, bukan bukti sebab-akibat untuk individu. Faktor teratas terutama berkaitan dengan recency, volume, dan nilai belanja.

Fitur global	Importance
days_since_last_purchase	0.147
total_orders	0.089
total_spend_usd	0.077
orders_per_year	0.072
customer_tenure_days	0.062
avg_order_value_usd	0.061
reviews_per_order	0.053
age	0.049
avg_review_score	0.044
reviews_given	0.040

7. Diskusi, etika, dan keterbatasan

Model menunjukkan kemampuan pemisahan moderat (ROC-AUC 0,733), tetapi precision 0,322 berarti sebagian besar pelanggan yang ditandai belum tentu churn. Rekomendasi yang aman adalah menggunakan skor sebagai prioritas untuk outreach yang proporsional, dengan keputusan akhir tetap pada manusia. Jangan gunakan prediksi sebagai alasan untuk memperlakukan pelanggan secara diskriminatif.

Risiko/keterbatasan	Mitigasi atau konsekuensi
Provenance dan lisensi tidak tercatat	Tidak boleh diasumsikan layak untuk produksi; verifikasi sumber dan izin terlebih dahulu.
Label historis bukan kausalitas	Jangan menyebut faktor model sebagai penyebab churn; lakukan eksperimen retensi terkontrol.
Bias dan representativitas tidak dievaluasi	Audit per kelompok yang sah dan minimalkan penggunaan atribut sensitif.
Drift dan kalibrasi belum diuji	Pantau performa setelah deployment dan retrain hanya dengan governance yang jelas.
LLM dapat menghasilkan klaim tak didukung	Grounding, prompt inspection, human review, logging, dan evaluasi kasus uji diperlukan.
Data pelanggan berpotensi pribadi	Batasi akses, minimalkan data pada prompt, dan patuhi kebijakan retensi/privasi.

8. Kesimpulan dan reproduksibilitas

(1) Pipeline referensi berhasil menghubungkan BI, prediksi churn, dan komunikasi berbantuan LLM. (2) Pada hold-out test set, Random Forest mencapai ROC-AUC 0,733 dan F1 churn 0,387 pada threshold 0,50. (3) Ambang keputusan mengubah trade-off operasional secara nyata. (4) LLM diposisikan sebagai pembantu komunikasi evidence, bukan pembuat keputusan atau penjelas kausal. (5) Data dan evaluasi saat ini mendukung pembelajaran/reproduce, bukan deployment produksi.

Untuk menjalankan ulang dari folder simulation: `pip install -r requirements.txt`, kemudian `python data_prep.py`, `python ml_model.py`, dan `streamlit run app.py`. Untuk LLM, jalankan ollama serve, unduh model llama3.2, lalu gunakan `python vai_analyst.py`. PDF ini dibuat dari artefak yang ada pada repository dan tidak menggantikan verifikasi data atau evaluasi pengguna nyata.

Catatan pengungkapan AI: laporan ini disusun dengan bantuan AI berbasis kode, lalu angka dan klaimnya ditautkan ke file `data_quality_report.json`, `model_metrics.json`, `feature_importance.csv`, serta implementasi pipeline pada repository.